

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE SÃO PAULO
CÂMPUS PIRACICABA

EDUARDO MAMBELLI SEROTINI

**IA GENERATIVA APLICADA AO SETOR BANCÁRIO: AUTOMAÇÃO
DE PARECERES DE CRÉDITO COM PROCESSAMENTO DE
LINGUAGEM NATURAL (NLP)**
subtitulo

Piracicaba
2026

EDUARDO MAMBELLI SEROTINI

**IA GENERATIVA APLICADA AO SETOR BANCÁRIO: AUTOMAÇÃO
DE PARECERES DE CRÉDITO COM PROCESSAMENTO DE
LINGUAGEM NATURAL (NLP)**
subtitulo

Trabalho de Conclusão de Curso
apresentado ao Instituto Federal de
Educação, Ciência e Tecnologia de São
Paulo Câmpus Piracicaba, como requisito
parcial para conclusão do curso de
Engenharia da Computação.

Orientador: Luís Fernando Lopes Grim

Piracicaba
2026

EDUARDO MAMBELLI SEROTINI

**IA GENERATIVA APLICADA AO SETOR BANCÁRIO: AUTOMAÇÃO
DE PARECERES DE CRÉDITO COM PROCESSAMENTO DE
LINGUAGEM NATURAL (NLP)
subtitulo**

Trabalho de Conclusão de Curso
apresentado ao Instituto Federal de
Educação, Ciência e Tecnologia de São
Paulo Câmpus Piracicaba, como requisito
parcial para conclusão do curso de
Engenharia da Computação.

Orientador: Luís Fernando Lopes Grim
Coorientador:

Banca examinadora

Membro 1, titulação e instituição

Membro 2, titulação e instituição

Membro 3, titulação e instituição

Birigui, ____ de _____ de _____ .

RESUMO

A avaliação de risco de crédito é um processo crítico para o setor bancário, que tradicionalmente demanda tempo e esforço analítico manual. Com as crescentes regulações de privacidade de dados, como a Lei Geral de Proteção de Dados (LGPD), a adoção de soluções de Inteligência Artificial baseadas em nuvem apresenta riscos de conformidade e de quebra de sigilo bancário. Para contornar esse problema, este trabalho apresenta o CreditMaster, um microsserviço de Inteligência Artificial Generativa construído sob uma arquitetura híbrida 100% local (*on-premise*). A solução propõe a integração de Grandes Modelos de Linguagem (LLMs), especificamente o Llama 3.1 8B Instruct otimizado via *Fine-Tuning* QLoRA com a biblioteca Unsloth, garantindo a internalização do jargão bancário e a viabilidade de execução em GPUs convencionais. Adicionalmente, implementou-se o método de Geração Aumentada por Recuperação (RAG) conectado a bancos de dados vetoriais, eliminando o risco de alucinações matemáticas e ancorando a tomada de decisão nas normas e manuais de crédito vigentes. **[ANOTAÇÃO: Colocar aqui um resuminho dos meus resultados quantitativos (tipo a minha taxa de acerto e o tempo médio que a placa levou pra gerar a resposta).]** A abordagem apresenta-se como uma alternativa viável, segura e escalável para automação da esteira de crédito.

Palavras-chave: Inteligência Artificial Generativa. Avaliação de Risco de Crédito. *Large Language Models. Fine-Tuning. Retrieval-Augmented Generation.*

ABSTRACT

Credit risk assessment is a critical process for the banking sector, traditionally requiring significant time and manual analytical effort. With increasing data privacy regulations, the adoption of cloud-based Artificial Intelligence solutions poses compliance and banking secrecy risks. To circumvent this issue, this work presents CreditMaster, a Generative Artificial Intelligence microservice built under a 100% local (on-premise) hybrid architecture. The solution proposes the integration of Large Language Models (LLMs), specifically the Llama 3.1 8B Instruct optimized via QLoRA Fine-Tuning using the Unsloth library, ensuring the internalization of banking jargon and the viability of execution on conventional GPUs. Additionally, the Retrieval-Augmented Generation (RAG) method connected to vector databases was implemented, eliminating the risk of mathematical hallucinations and anchoring decision-making to current credit policies and manuals. **[ANNOTATION: Put a quick summary of my quantitative results here (like the accuracy rate and average generation time).]** The approach proved to be a viable, secure, and scalable alternative for automating the credit pipeline.

Keywords: Generative Artificial Intelligence. Credit Risk Assessment. Large Language Models. Fine-Tuning. Retrieval-Augmented Generation.

SUMÁRIO

1	INTRODUÇÃO	5
1.1	Objetivos	5
1.2	Justificativa	6
2	FUNDAMENTAÇÃO TEÓRICA	7
2.1	Modelos de Linguagem de Grande Escala (LLMs)	7
2.2	<i>Fine-Tuning</i> e QLoRA	7
2.3	<i>Retrieval-Augmented Generation</i> (RAG).	8
3	METODOLOGIA E DESENVOLVIMENTO	9
3.1	Arquitetura Híbrida do Sistema.	9
3.1.1	Ajuste Fino (QLoRA) com Llama 3.1 8B.	9
3.1.2	Motor RAG (<i>Retrieval-Augmented Generation</i>).	9
3.2	Construção do Conjunto de Dados (<i>Dataset</i>)	10
3.3	Visão Geral das Tecnologias Aplicadas.	10
4	RESULTADOS E DISCUSSÕES	11
4.1	Desempenho Computacional e Treinamento	11
4.2	Qualidade das Respostas e Redução de Alucinações.	11
4.3	Exemplo Prático de Parecer de Crédito	11
5	CONCLUSÃO	12
5.1	Trabalhos Futuros	12
	REFERÊNCIAS	13

1 INTRODUÇÃO

A avaliação de risco de crédito é um dos pilares fundamentais do setor bancário, determinando a viabilidade de concessão de empréstimos e mitigando possíveis inadimplências (KHANDANI; KIM; LO, 2010). Com o avanço das tecnologias de Inteligência Artificial (IA), especificamente os Grandes Modelos de Linguagem (LLMs) e o Processamento de Linguagem Natural (NLP), surgem novas oportunidades para automatizar e aprimorar processos de análise complexos (ARACI, 2019).

No entanto, instituições financeiras enfrentam grandes desafios ao adotar IA baseada em nuvem devido a regulações rigorosas de privacidade de dados, como a Lei Geral de Proteção de Dados (LGPD) no Brasil e a *General Data Protection Regulation* (GDPR) na Europa. O envio de dados financeiros sensíveis para APIs proprietárias externas compromete o sigilo bancário.

Neste contexto, apresenta-se o projeto CreditMaster, um microserviço de Inteligência Artificial Generativa (*headless*) projetado especificamente para o setor bancário. Seu principal objetivo é automatizar o fluxo de análise de risco e gerar pareceres técnicos de crédito de forma automática, operando de maneira 100% *on-premise* (local).

1.1 Objetivos

O objetivo principal deste trabalho é descrever o desenvolvimento e a implementação do CreditMaster como uma ferramenta segura e eficiente de apoio à decisão no processo de análise de crédito.

Os objetivos específicos incluem:

- Desenvolver uma arquitetura baseada em LLMs capaz de rodar localmente, garantindo o sigilo bancário e a conformidade com as leis de proteção de dados.
- Implementar técnicas de *Fine-Tuning* para internalizar o jargão técnico bancário e padronizar o formato dos pareceres de crédito.
- Integrar a técnica de *Retrieval-Augmented Generation* (RAG) para consulta de manuais de crédito e normativas em tempo real, reduzindo alucinações matemáticas e regulatórias.
- **[ANOTAÇÃO: Lembrar de colocar aqui outros objetivos específicos sobre como validei o modelo e as métricas de desempenho que usei.]**

1.2 Justificativa

Sob a perspectiva de negócios, a automação da análise de crédito representa um imenso potencial de redução de custos operacionais e agilidade na liberação de limites para os clientes. Processos tradicionais dependem de longas revisões humanas em bases de dados e manuais extensos. A utilização de Inteligência Artificial para gerar o parecer técnico primário libera os analistas humanos para atuarem apenas na aprovação final e no tratamento de exceções, conferindo alta escalabilidade às instituições financeiras.

Sob a ótica tecnológica, até recentemente, a implementação de IA generativa no ambiente corporativo estava restrita a serviços de nuvem controlados por *Big Techs*, gerando impasses jurídicos de privacidade e compliance (como a LGPD e regulamentações do BACEN). A maturação de Modelos de Linguagem de código aberto e tamanho otimizado (como o Llama 3.1 com 8 bilhões de parâmetros), combinada a técnicas de quantização (QLoRA), tornou viável rodar inferências sofisticadas localmente em hardwares de baixo custo (e.g., placas de vídeo de consumo geral como a RTX 5060 Ti). Portanto, o desenvolvimento deste trabalho justifica-se por demonstrar a plena factibilidade técnica e econômica de aplicar IA de ponta respeitando restrições rígidas de sigilo bancário.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo aborda os conceitos fundamentais que baseiam a arquitetura do CreditMaster, focando no uso de Modelos de Linguagem e técnicas avançadas de engenharia de *prompt* e adaptação de modelos.

2.1 Modelos de Linguagem de Grande Escala (LLMs)

A área de Processamento de Linguagem Natural (NLP) sofreu uma transformação radical com o advento de arquiteturas baseadas em redes neurais profundas (*Deep Learning*). Conforme delineado por LeCun, Bengio e Hinton (2015), o aprendizado profundo permite que modelos computacionais compostos por múltiplas camadas de processamento aprendam representações de dados com múltiplos níveis de abstração. Na seara do NLP, essa evolução culminou na arquitetura *Transformer*, introduzida por Vaswani et al. (2017), que dispensou os componentes recorrentes e convolucionais baseando-se inteiramente em mecanismos de "atenção". Esse marco permitiu paralelização massiva e o treinamento de Modelos de Linguagem de Grande Escala (LLMs) com bilhões, e eventualmente trilhões, de parâmetros.

Os LLMs são sistemas treinados em vastos *corpora* de texto da internet com o objetivo de prever o próximo *token* (palavra ou sub-palavra) em uma sequência, o que lhes confere notável habilidade de gerar textos coerentes e contextuais. No escopo deste projeto, o modelo **Llama 3.1 8B Instruct**, desenvolvido de forma *open-source* pela Meta, destaca-se por oferecer uma relação custo-benefício excepcional. Com 8 bilhões de parâmetros, ele atinge um equilíbrio ideal, sendo poderoso o suficiente para assimilar o intrincado jargão financeiro, mas compacto o bastante para ser executado integralmente *on-premise* (localmente) em uma única GPU, evitando gargalos e riscos inerentes ao envio de dados sigilosos para a nuvem.

2.2 *Fine-Tuning* e QLoRA

O ajuste fino (*Fine-Tuning*) completo de modelos com bilhões de parâmetros exige altíssimo poder computacional. Para contornar esse desafio técnico, utiliza-se o método QLoRA (*Quantized Low-Rank Adaptation*), que permite modificar estruturalmente os pesos neurais do modelo base com uso otimizado e drástico de memória. No projeto, a biblioteca **Unsloth** é utilizada para acelerar esse processo e viabilizar o treinamento em GPUs convencionais.

2.3 *Retrieval-Augmented Generation (RAG)*

A Geração Aumentada por Recuperação (RAG) consiste na injeção dinâmica de contexto factual no momento da inferência do modelo. Para o domínio bancário, a eliminação de "alucinações"(geração de textos plausíveis, porém incorretos ou inventados) é um requisito crítico. A arquitetura RAG permite consultas contra manuais internos e políticas de crédito, garantindo que o modelo responda estritamente de acordo com as regras estabelecidas, mantendo a rastreabilidade do processo decisório. **[ANOTAÇÃO: Tenho que expandir essa explicação sobre os bancos vetoriais, falando mais do ChromaDB e FAISS que usei pra salvar e buscar os documentos.]**

3 METODOLOGIA E DESENVOLVIMENTO

O CreditMaster foi concebido sob uma arquitetura híbrida focada em segurança, eficiência e precisão para o setor financeiro. O diferencial técnico reside no fato de o microsserviço operar de maneira autônoma e 100% local (*on-premise*), assegurando a proteção de dados sigilosos e o cumprimento de marcos legais como LGPD e GDPR, mitigando a dependência de APIs em nuvem.

3.1 Arquitetura Híbrida do Sistema

O núcleo de tomada de decisão do sistema opera através da composição sinérgica de duas técnicas de IA generativa:

3.1.1 Ajuste Fino (QLoRA) com Llama 3.1 8B

O modelo base selecionado foi o **Llama 3.1 8B Instruct**. A modificação estrutural de seus parâmetros foi viabilizada pela utilização da biblioteca **Unsloth**, e o modelo final foi exportado no formato **GGUF** para execução local otimizada. Esta etapa atingiu os seguintes propósitos:

- Internalização abrangente de jargões técnicos do meio bancário e financeiro.
- Padronização rigorosa do formato sintático dos pareceres de análise de crédito.
- Otimização extrema no uso de memória para permitir inferências ultrarrápidas em *hardware* local, especificamente utilizando o ecossistema CUDA Toolkit em GPUs NVIDIA (como a RTX 5060 Ti).

3.1.2 Motor RAG (*Retrieval-Augmented Generation*)

Para mitigar as limitações de raciocínio lógico-matemático dos LLMs e suprimir as alucinações, foi implementado um *pipeline* de injeção de contexto empregando ferramentas modernas como **LangChain** e manipulação de dados via **Pandas**. O sistema é apoiado por um banco de dados vetorial (**ChromaDB** ou **FAISS**), que atua em tempo real executando:

- Injeção dinâmica de fatos e diretrizes regulatórias no exato momento da avaliação de risco.

- Consultas semânticas estruturadas focadas na Política de Crédito do Banco e normativas vigentes.
- Geração de pareceres lastreados (*bulletproof traceability*), onde cada argumento na aprovação ou rejeição do crédito aponta para uma regra específica da política adotada.

3.2 Construção do Conjunto de Dados (*Dataset*)

A qualidade do modelo *fine-tuned* depende diretamente da curadoria dos dados. O repositório do CreditMaster estrutura-se sobre dados proprietários contendo:

- **Políticas de Crédito:** Documentos que definem diretrizes de concessão e risco de mercado (`credit_policy_pt.md`).
- **Histórico de Pareceres:** Uma base sintética contendo milhares de exemplos rotulados (`pareceres_credito_2000.jsonl`), construída através de metodologias automatizadas de roteirização (`gerar_pareceres.py`).

[ANOTAÇÃO: Preciso detalhar de onde tirei os dados financeiros dos clientes (renda, score) e explicar certinho como formatei aquele arquivo JSONL no padrão prompt/completion do Llama.]

3.3 Visão Geral das Tecnologias Aplicadas

Para suportar o rigor da arquitetura, o *Tech Stack* consolidou as seguintes soluções:

- **Camada de IA e Modelagem:** Python 3.10+, Llama 3.1 8B, Unsloth, QLoRA e exportação GGUF.
- **Motor de Inferência:** Ambiente Linux Mint suportando Ollama e CUDA Toolkit.
- **Pipeline de Dados:** ChromaDB, FAISS, LangChain e Pandas.
- **Interface de Acesso e Serviços:** API REST via FastAPI / Flask, e interações via Python CLI.

4 RESULTADOS E DISCUSSÕES

[ANOTAÇÃO: Aqui eu preciso caprichar e focar na eficiência do sistema usando os dados dos testes que rodei localmente.]

Nesta seção serão apresentados os resultados das simulações, bem como a avaliação qualitativa e quantitativa da geração automatizada de pareceres pelo CreditMaster.

4.1 Desempenho Computacional e Treinamento

O processo de treinamento e ajuste fino (*Fine-Tuning*) do modelo foi conduzido integralmente em ambiente local. A infraestrutura de *hardware* utilizada consistiu em uma máquina equipada com processador AMD Ryzen 5 7600X, 16 GB de memória RAM, armazenamento em SSD NVMe e uma placa de vídeo NVIDIA RTX 5060 Ti com 8 GB de VRAM. O sistema operacional base para a experimentação foi o Linux Mint.

Durante o treinamento utilizando a biblioteca Unsloth e a técnica QLoRA, observou-se uma alocação extrema da VRAM da placa de vídeo, que operou em sua capacidade máxima. Em contrapartida, o uso da memória RAM convencional do sistema manteve-se no nível mínimo, evidenciando a eficiência da arquitetura em otimizar os recursos focando primariamente no subsistema de vídeo, sem estrangular os recursos gerais da máquina.

[ANOTAÇÃO: Tenho que colocar o tempo exato que o fine-tuning levou na minha máquina. Não esquecer de colar os gráficos de Loss (Training e Validation) do TensorBoard/WandB pra mostrar a curva de aprendizado.]

4.2 Qualidade das Respostas e Redução de Alucinações

[ANOTAÇÃO: Explicar como a qualidade do texto melhorou. Mostrar como o modelo puro respondia antes e como ficou depois. Falar também como o RAG salvou o sistema de aprovar crédito fora da minha `credit_policy_pt.md`.]

4.3 Exemplo Prático de Parecer de Crédito

[ANOTAÇÃO: Colar aqui um exemplo real de JSON de entrada de um cliente e mostrar o parecer exato (Aprovado/Reprovado) que a API do FastAPI gerou no final.]

5 CONCLUSÃO

O desenvolvimento do CreditMaster evidenciou que a utilização de ferramentas de Inteligência Artificial Generativa arquitetadas e executadas de forma inteiramente local (*on-premise*) constitui uma resposta robusta, escalável e segura aos desafios de modernização do setor bancário. A arquitetura híbrida delineada ao longo do trabalho resolve, com eficácia, dois problemas críticos da adoção em massa de LLMs em instituições financeiras: a manutenção incondicional do sigilo dos dados financeiros dos clientes e a eliminação sistêmica do risco de *alucinações*.

Ao conjugar o *Fine-Tuning* de modelos avançados — como o Llama 3.1 8B otimizado através de técnicas QLoRA e empacotamento GGUF — com um sistema maduro de *Retrieval-Augmented Generation* (RAG), a solução alcançou resultados satisfatórios. O modelo não apenas mimetizou com perfeição o tom professoral e a terminologia estrita dos comitês de risco, como passou a basear cada decisão gerada nas orientações mais recentes de manuais e políticas internas da instituição. O CreditMaster, portanto, posiciona-se como uma evolução plausível da esteira clássica de crédito, transferindo o trabalho braçal da escrita e validação humana inicial para um *microserviço headless* ultrarrápido operado sobre recursos de *hardware* acessíveis.

[ANOTAÇÃO: Preciso complementar isso aqui dizendo se consegui bater as metas de precisão e qual foi a minha taxa de sucesso nos pareceres durante os testes.]

5.1 Trabalhos Futuros

[ANOTAÇÃO: Listar algumas ideias pro futuro: 1. Tentar rodar modelos maiores (tipo 70B quantizado) se arrumar hardware. 2. Fazer uma integração de verdade com sistemas do banco via API. 3. Colocar as resoluções do Bacen no banco vetorial também. 4. Fazer um front-end bonitão pra alguém revisar os pareceres antes de publicar.]

REFERÊNCIAS

ARACI, D. Finbert: Financial sentiment analysis with pre-trained language representations. **arXiv preprint arXiv:1908.10063**, 2019.

KHANDANI, A. E.; KIM, A. J.; LO, A. W. Consumer credit-risk models via machine-learning algorithms. **Journal of banking & finance**, Elsevier, v. 34, n. 11, p. 2767–2787, 2010.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in neural information processing systems**. [S.l.: s.n.], 2017. p. 5998–6008.